

Ciencia de Datos

Ingeniería Industrial

UTN FRBA

curso I5571

clase_01

Análisis exploratorio de datos. Descripción estadística.



agenda_clase_01

EDA

- Boxplot
- Outliers utilizando quantiles
- Correlación Lineal (Pearson)

Lab

- EDA Subtes
- EDA Google Play


Presentación TP Parcial

Histograma de frecuencias


Herramienta para estimar densidad empírica

Distribución de probabilidad

La distribución de probabilidad es la **función** que asigna probabilidades de ocurrencia a distintos estados posibles de un experimento [1]. Es la **descripción** de un fenómeno **aleatorio** en términos de un espacio de muestreos y probabilidades de eventos.



Muestreo desde una función de densidad de probabilidad




Suponiendo que **conocemos** la función de densidad de probabilidad de una variable aleatoria, vamos a **muestrear** multiples veces dicha funcion y obtener distintos valores de la variable aleatoria a simular. En el caso contrario si solo tenemos los datos y no conocemos la funcion de densidad que los genero se abordaran estrategias de maxima verosimilitud o metodos de estimacion no parametrica de la densidad [2]

[1] https://en.wikipedia.org/wiki/Maximum_likelihood_estimation

[2] https://en.wikipedia.org/wiki/Kernel_density_estimation .

Histograma de frecuencias



El histograma representa la frecuencia relativa de aparición de un valor de la variable aleatoria mediante la altura de las barras.

En el eje X tendremos los distintos valores que puede tomar una variable aleatoria a observar. En vez de contar valores únicos contamos todos los valores que caigan en un rango, es decir, la primera barra por ejemplo cuenta la cantidad de veces que la VA tomó los valores entre 100 y 125. La segunda barra cuenta la cantidad de veces que la VA tomó valores entre 125 y 150, etc.

Entonces al tomar muchas muestras (muestrear, samplear) una variable aleatoria podemos empíricamente entender cómo se distribuye los valores que la VA puede tomar. Entonces podemos decir que con un histograma podemos aproximar empíricamente la distribución de probabilidad.

Histograma de frecuencias

Cantidad de muestras por bin/caja


Funcion delta (contador)

$$n_k = \sum \delta(x_{(kj)}) \quad \delta(x_{(ij)}) = 1$$


Muestras totales en los K bins

$$n = \sum_{i=1}^k \sum_{j=0}^{n_k} \delta(x_{(kj)})$$

Histograma de frecuencias




Histograma con bins = 10



Histograma con bins = 40


Histogramas

Hist. d1




Histograma sobre 500
muestras de una
distribución d1 normal
 $\mu = 15$, $\sigma = 3$

Hist. d2




Histograma sobre 500
muestras de una
distribución d2 normal
 $\mu = 25$, $\sigma = 5$

Hist. d1 & d2



Los dos histogramas en
simultáneo.


Hist. d1 + d2




Histograma realizado sobre
la suma de las 2 muestras
obtenidas de las
distribuciones d1 y d2.

Distribución uniforme

Distribución de densidad de probabilidad.



Distribución de probabilidad acumulada.



Rango de valores posibles.


$$f(x) = \begin{cases} \frac{1}{b-a} & \text{if } a \leq x \leq b \\ 0 & \text{else} \end{cases}$$

$$F(x) = \begin{cases} 0 & \text{if } x < a \\ \frac{x-a}{b-a} & \text{if } a \leq x \leq b \\ 1 & \text{if } x > b \end{cases}$$


La distribución de probabilidad uniforme asigna la misma probabilidad de ocurrencia a cada valor dentro del rango que puede generar una variable aleatoria.

Muestreo desde distribución uniforme

Probabilidad
Empírica
De ocurrencia




Probabilidad
Acumulada de
Ocurrencia



Distribución gaussiana - normal

Distribución de densidad (verde) y acumulada (roja) de probabilidad.




Rango de valores posibles de la VA.

Distribución simétrica de VA continua. El parámetro μ define la esperanza y el sigma el desvío standard.

Suele utilizarse para modelar procesos reales en ciencias naturales, sociales, etc.

$$p(x) \sim \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[\frac{-1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right]$$

Muestreo de una distribución normal



Boxplot

Herramienta para estimar densidad empírica

Cuantiles

Los cuantiles suelen usarse como límites entre los grupos que dividen la distribución de una variable aleatoria en partes iguales; entendidas estas como intervalos que comprenden la misma proporción de valores.

Los más populares son:

- Cuartiles, dividen la distribución en 4 partes iguales (0.25, 0.5, 0.75)
- Quintiles, dividen la dist. en 5 partes iguales (0.2, 0.4, 0.6, 0.8)
- Deciles, dividen la dist. en 10 partes iguales (0.1, 0.2.....0.9)
- Percentiles, dividen la dist. en 100 partes iguales (0.01.....0.99)


Cuantil & Cuartil

Datos Originales de una variable aleatoria

$X = [15, 7, 3, 22, 10, 8, 6, 7, 2, 11, 5, 12]$

Datos ordenados

$[2, 3, 5, 6, 7, 7, 8, 10, 11, 12, 15, 22]$



Min


1Q

2Q

3Q


Max

Boxplot



En este caso por ejemplo tenemos una variable/feature que se mide en un lapso de 11 segundos. Queremos entender cómo se distribuyen los valores de la variable en cuestión.

Boxplot




Cuartiles y Boxplots

Si ordenamos los datos de menor a mayor:

- El 25% de los datos será menor al 1er cuartil
- El 50% de los datos será menor al 2do cuartil (mediana)
- El 75% de los datos será menor al 3er cuartil
- Los valores que estén sobre el percentil 0.01 y 0.99 se podrían considerar outliers.

Cuartiles y Boxplots



Filtrar por Cuantiles

Muchas veces, con el fin de quitar outliers de la distribución de datos que deseamos analizar, lo que podemos realizar es:

- Quitar todos los datos que estén por encima del Percentil 99
- Quitar todos los datos que estén por debajo del Percentil 1
- Quitar todos los datos que estén por fuera del $1.5 * \text{IQR}$ (Interquartile Range).

Cuidado! Quitar datos del dataset dependerá de cada caso, es importante entender las consecuencias de quitar instancias consideradas anomalías.

Mean, Median & Outliers



Mean, Median & Outliers - "sabiduría de la multitud" (wisdom of the crowd)

¿Cuánto pesa un elefante? — Histograma y efecto de los outliers en media vs. mediana

Datos: estimaciones de peso de elefante adulto dadas por los 23 participantes de la encuesta (combinando la pregunta en kg/toneladas y la pregunta en gramos, normalizadas a kg). Escala logarítmica en el histograma por la enorme dispersión de las respuestas (de 50 kg a 3.000.000.000 kg).

Dataset: Solo pregunta en gramos

Quitar el outlier más extremo

Auto (quitar todos)

Reiniciar

n (datos restantes)

21

Media


143.04 M kg

Mediana


3.00 mil kg

Últ. valor quitado

-




Boxplot & histograma



Un boxplot y un histograma en 1D son sinónimos y complementos para visualizar la densidad de probabilidad empírica de una variable.

Scatterplot + Histograma



$$x \in \mathbb{R}^2$$

Es posible visualizar muestras en dos dimensiones con un scatterplot y simultáneamente histogramas en cada una de las variables que caracterizan a cada muestra. De igual manera en lugar de los histogramas podría haber un boxplot.

Correlación Lineal


Medida que expresa si dos variables aleatorias co-varían linealmente.

Correlación lineal (Pearson)

Es una forma de medir cuán cercanas están dos variables x e y (features) a tener una relación lineal entre ellas.

$$r = \frac{\sum_i^n (x_{1i} - \bar{x}_1)(x_{2i} - \bar{x}_2)}{[\sum_i^n (x_{1i} - \bar{x}_1)^2 (x_{2i} - \bar{x}_2)^2]^{1/2}}$$

Matriz de correlación



$$R = \begin{bmatrix} r_{11} & r_{12} & r_{13} & r_{14} & r_{15} \\ r_{21} & r_{22} & r_{23} & r_{24} & r_{25} \\ r_{31} & r_{32} & r_{33} & r_{34} & r_{35} \\ r_{41} & r_{42} & r_{43} & r_{44} & r_{45} \\ r_{51} & r_{52} & r_{53} & r_{54} & r_{55} \end{bmatrix}$$

The matrix R is a 5×5 matrix of correlation coefficients r_{ij} . The horizontal dimension is labeled d and the vertical dimension is labeled d . The element r_{24} is circled in red. A pink arrow points from r_{24} to the formula for r :


$$r = \frac{\sum_i^n (x_{1i} - \bar{x}_1)(x_{2i} - \bar{x}_2)}{[\sum_i^n (x_{1i} - \bar{x}_1)^2 (x_{2i} - \bar{x}_2)^2]^{1/2}}$$

$\mathcal{X} \in \mathbb{R}^d$

Correlación lineal (Pearson)







Correlación pairwise entre variables



En el ejemplo tenemos 6 variables/features. Podemos calcular la correlación lineal de Pearson par-a-par y visualizar con un heatmap.

Atención: la correlación de Pearson **sólo** mide relación lineal entre variables. Que no exista correlación lineal no quiere decir que no exista relación alguna. Puede existir relación no lineal.

Correlación lineal: trampas




Los 4 datasets tienen las mismas estadísticas descriptivas, sin embargo se ven muy distintos cuando se visualizan:

Media $X = 9$
 $R_{xy} = 0.81$

Correlation is not causation

US spending on science, space, and technology correlates with Suicides by hanging, strangulation and suffocation

Correlation: 99.79% ($r=0.99789126$)



tylervigen.com

Data sources: U.S. Office of Management and Budget and Centers for Disease Control & Prevention

Pearson correlation in Python



```
x = np.array([[2,2],[3,3]])
```

```
R1 = np.corrcoef(x)
```

Pandas: Concat, Join, Merge

Pandas nos da la opción de poder combinar dataframes de distintas formas:


- **Concat**, unir dos dataframes por columnas o filas
- **Join & Merge** (vlookup)

Pandas: Concat


Podremos concatenar dos dataframes por columnas o por filas. Esto quiere decir que si concatenamos por:

- Columnas: la cantidad de filas de ambos tiene que ser igual
- Filas: la cantidad de columnas de ambos tiene que ser igual

Concatenar
por columnas




Concatenar
por filas



Si la cantidad de filas o columnas no son iguales dependiendo el caso pandas generará nuevas columnas y filas para satisfacer la desigualdad y estas estarán llenas con NaNs.

Pandas: Join & Merge

Es lo más cercano al “vlookup” en excel. Esto permite poder tener una columna “key” de referencia en dos tablas (A y B). Permite llevar los datos de B asociados a “key” a la tabla A asociándose a “key” también.



Pandas: Merge

```
In [39]: left = pd.DataFrame({'key': ['K0', 'K1', 'K2', 'K3'],  
.....:                      'A': ['A0', 'A1', 'A2', 'A3'],  
.....:                      'B': ['B0', 'B1', 'B2', 'B3']})  
.....:  
  
In [40]: right = pd.DataFrame({'key': ['K0', 'K1', 'K2', 'K3'],  
.....:                        'C': ['C0', 'C1', 'C2', 'C3'],  
.....:                        'D': ['D0', 'D1', 'D2', 'D3']})  
.....:  
.....:  
  
In [41]: result = pd.merge(left, right, on='key')
```

left				right				Result					
	key	A	B		key	C	D		key	A	B	C	D
0	K0	A0	B0	0	K0	C0	D0	0	K0	A0	B0	C0	D0
1	K1	A1	B1	1	K1	C1	D1	1	K1	A1	B1	C1	D1
2	K2	A2	B2	2	K2	C2	D2	2	K2	A2	B2	C2	D2
3	K3	A3	B3	3	K3	C3	D3	3	K3	A3	B3	C3	D3

Pandas: pivot_table

df

	foo	bar	baz	zoo
0	one	A	1	x
1	one	A	2	y
2	one	B	3	z
3	two	A	4	q
4	two	B	5	w
5	two	B	6	t



```
df.pivot_table (index='foo',  
                 columns='bar',  
                 values='baz',  
                 aggfunc='sum')
```

bar	A	B
foo		
one	1 + 2	3
two	4	5 + 6

A agarrar la PyLA

